

Project 1 on Machine Learning: regression analysis, resampling methods and gradient descent

Tim Herrmann Holmen

FYS-STK4155

Department of Physics

Dette prosjektet er en vandring gjennom metodene innen dataanalyse som har ledet til det vi idag kaller maskinl ring. Hovedm let er   studere i detalj diverse regresjonsmetoder, som ordinary least squares, ridge regresjon og lasso regresjon. Resampling teknikker som bootstrap og kryssvalidering lar oss vurdere og velge den beste metoden for problemet. For   optimalisere parametrene (hvilke parametre er det her snakk om?: det er selve parametrene og hyperparametrene) vil vi bruke gradient descent, og teste ulike metoder for   utf re denne beregningen, som best r av derivasjon. Vi har studert newtons metode og automatiserte derivasjons metoder, for   optimalisere parametrene i modellene. Polynomene vi utvikler skal passe til en spesifikk dimensjonal funksjon kalt Runges funksjon, med et st y element, dermed har vi det analytiske svaret tilgjengelig.

CONTENTS

I. Introduction	1
A. 2a The motivation.	1
B. 2b What has been done and what i do.	1
1. Linear Models	1
2. Resampling techniques	2
3. Optimization	2
C. 2c) The structure of the report,	2
II. Conclusion	2

I. INTRODUCTION

A. 2a The motivation.

En av grunnene til   tilpasse funksjoner med polynomer, er at man kan  ke polynomgraden vilk rlig, og dermed utforske ulike polynomgrader med tilh rende parametre for   se hvilken polynomgrad som gir en best tilpasning. En utfordring er at man tilsynelatende kan f  en optimal tilpasning ved    ke polynomgraden, og dermed bedre tilpasse polynomet til dataen man  nsker   beskrive. Runge funksjon er en klassisk test funksjon fordi den oppf rer seg som en gaussisk fordeling i intervallet $[-1, 1]$, utenfor dette intervallet er funksjonen forholdsvis flat. For runge vil dette si at en stadig h yere polynomgrad ikke n dvendigvis gir en bedre modell i ytterpunktene, det finnes en begrensning allerede i formen p  dataen, som kommer fra runge funksjonen. Dette fenomenet blir tydelig dersom man kartlegger "bias-variance" tradeoff. Dersom man tilpasser polynomer av  kende grad, vil man se at feilen mellom modellen og treningsdataen blir mindre for h yere kompleksitet, derimot vil feilen mellom modellen og test data, gradvis  ke med h yere kompleksitet, dette kalles overtilpasning. At test error gradvis  ker, og trening error gradvis minker, er et resultat av bias og varians, ved h yere kompleksitet, blir bias mindre, som blir tydelig gjennom

trening error, variansen vil derimot  ke, som blir tydelig gjennom test error. Det er slik ettersom erroren er en sum av kvadrert bias, varians og kvadrert st y. At bias minker for treningsdata, er et tegn p  overtilpasning, at variansen  ker, kommer av at modellen er overtilpasset treningsdata, og dermed f r en d rligere tilpasning til annen type data, fra samme fordeling. I andre enden, kan man ha en modell som er d rligere tilpasset treningsdataen, den har h yere bias, men samtidig vil variansen v re mindre dersom man tester modellen p  en annen datagruppe fra samme fordeling. M let er   finne en balanse mellom bias og varians som gir den laveste mulige totale feilen.

The bias variance tradeoff:

$$E[(y - \tilde{y})^2] = \frac{1}{n} \sum_i (f_i - E[\tilde{y}])^2 + \frac{1}{n} \sum_i (\tilde{y}_i - E[\tilde{y}])^2 + \sigma^2 \quad (1)$$

$$MSE = Bias^2 + Var[\tilde{y}] + irreducible\ noise$$

The bias measures how far the average prediction is from the truth. The variance measures how much the prediction moves when the training set is redrawn. The irreducible error is the variance of the noise itself.

To further explore this tradeoff

B. 2b What has been done and what i do.

1. Linear Models

a. OLS

b. Ridge

c. Lasso

2. Resampling techniques

a. *Bootstrap*

b. *Kfold cross validation*

3. Optimization

a. *Gradient descent*

b. *Momentum*

c. *Adagrad*

d. *RMSprop*

e. *Adam*

f. *Stochastic gradient descent*

C. 2c) The structure of the report,

the last paragraph, one sentence per section, and where code can be found.

II. CONCLUSION